

UNIVERSIDADE FEDERAL DE SÃO CARLOS CAMPUS SOROCABA
CCGT - CIÊNCIA DA COMPUTAÇÃO

NOVAS TECNOLOGIAS EM BANCO DE DADOS
Prof. Dra. Sahudy Montenegro González

PROJETO PRÁTICO FASE FINAL: *Wikipedia - Serial Killers*
Grupo 3

Amanda Akemi Perina Kouchi - 813363
Daniel Oliveira Rocha - 813332

SOROCABA - SP
9 de Dezembro de 2025

ÍNDICE

1. DEFINIÇÃO DO TEMA E MODELAGEM.....	2
1.1 Introdução ao tema.....	2
1.2 Requisitos de negócio e objetivos de análise.....	2
1.3 Fontes dos dados.....	3
1.4 Projeto do DW.....	3
1.5 Mapeamento entre atributos.....	6
2. IMPLEMENTAÇÃO.....	10
2.1 Projeto físico.....	10
2.2 ETL.....	11
2.3 Consultas.....	12
3. CONSIDERAÇÕES FINAIS.....	15
4. BIBLIOGRAFIA.....	17

1. DEFINIÇÃO DO TEMA E MODELAGEM

Esta seção apresenta o tema escolhido e a proposta de modelagem do *Data Warehouse* (DW) desenvolvido. São descritos o contexto do tema, os objetivos de análise, as fontes de dados utilizadas, o modelo multidimensional proposto e o planejamento das transformações necessárias para a construção do DW.

1.1 Introdução ao tema

O tema escolhido é *Serial Killers*, baseado principalmente nas informações retiradas da página “Lista de *Serial Killers* por Número de Vítimas” da Wikipédia, que reúne dados sobre criminosos de diferentes países e períodos de tempo. A lista contém detalhes como nome do assassino, número estimado e comprovado de vítimas, país de atuação, período de atividade, métodos utilizados e *status* (preso, executado etc).

O objetivo do projeto é desenvolver um DW que permita a análise estruturada e multidimensional desses dados, de modo que um gestor da área criminal (criminalista, analista forense etc) possa identificar padrões ou tendências relacionados aos assassinatos em série.

Com o DW proposto, será possível a realização de consultas que envolvem fatores geográficos, temporais e demográficos, de maneira a permitir uma visão mais ampla sobre *serial killers* ao longo do tempo e em diferentes contextos.

1.2 Requisitos de negócio e objetivos de análise

Os requisitos de negócio são as principais perguntas que o gestor, nesse caso um criminalista ou analista forense, conseguirá responder utilizando o DW. Eles funcionam como consultas conceituais que são viabilizadas a partir da modelagem multidimensional e das medidas da tabela fato.

Nesse sentido, a partir do tema escolhido, foram definidos alguns requisitos, que servirão como parâmetros para as consultas e visualizações:

1. Qual a soma total de vítimas (confirmadas e possíveis) dos assassinos que atuaram em mais de um país?
2. Qual a idade média de início dos assassinatos por gênero?
3. A duração média dos anos em atividade dos *Serial Killers* diminuiu após o teste de DNA começar a ser usado em investigações criminais?

4. Comparando assassinos da "América do Sul" vs. "América do Norte", qual deles tem o maior número de *serial killers* com *status* "PRESO" para aqueles que iniciaram atividade nos anos "1990"?

1.3 Fontes dos dados

A fonte principal de dados utilizada é a página "[List of serial killers by number of victims](#)" da Wikipédia, que reúne informações sobre assassinos em série ao redor do mundo, incluindo o número confirmado e estimado de vítimas, anos e país de atuação e *status* atual do criminoso.

Os dados serão obtidos via API e *scraping* da página da Wikipédia. Essa extração serve como base para a construção do DW.

Todavia, algumas informações - como o gênero do assassino e seu local de nascimento - não podem ser diretamente obtidas por meio da página principal: para esses dados, será feita uma coleta a partir das páginas individuais de cada criminoso, também da Wikipédia.

1.4 Projeto do DW

O modelo adotado na Figura 1 é um esquema estrela, composto por uma tabela fato e algumas dimensões que foram julgadas como necessárias para o projeto.




Figura 1 - Modelo multidimensional de dados

Sobre as dimensões e tabela fato:

- **Fato_Crimes:** É a tabela central do modelo multidimensional, que armazena todas as métricas associadas ao tema escolhido, de modo a permitir análises e agregações envolvendo o número de vítimas, duração da atividade, distribuições geográficas e temporais dos casos. A chave primária da tabela fato é a combinação de todas as *foreign keys* que a compõem:
 - `chave_ano_inicio` (FK): chave estrangeira da dimensão `Dim_Tempo`, armazena o período em que o assassino iniciou sua atividade.
 - `chave_ano_final` (FK): chave estrangeira da dimensão `Dim_Tempo`, armazena o período em que o assassino finalizou sua atividade.
 - `chave_ponte_local` (FK): chave estrangeira da dimensão `Ponte_Localização`, conectada às informações sobre o local dos crimes (país e continente).
 - `chave_assassino` (FK): chave estrangeira da dimensão `Dim_Assassino`, relacionada ao assassino correspondente.

A tabela também tem as métricas necessárias para cumprir os requisitos de negócio:

- `vitimas_possiveis`: número estimado de vítimas.
- `vitimas_confirmadas`: número confirmado de vítimas.
- `quantidade_de_paises`: como alguns assassinos atuaram em mais de um país, julgou-se coerente inserir uma métrica que contenha o número total de países em que o assassino cometeu crimes.
- `anos_em_atividade`: diferença entre o ano de início e o ano final de atividade do assassino.
- `idade_de_inicio`: idade do assassino quando começou as atividades criminosas.
- **Dim_Tempo:** Essa dimensão descreve os períodos de atividade dos assassinos, permitindo o agrupamento por década e ano. O principal objetivo da dimensão temporal é viabilizar análises de padrões históricos e evolução

temporal dos casos, além de facilitar comparações entre períodos. Os atributos que compõem a tabelas são:

- `chave_tempo` (PK): identifica a ocorrência temporal.
- `ano`: armazena um ano, que pode ser o de início ou de fim da atividade do assassino.
- `decada`: guarda a década do ano correspondente. O grupo acredita que guardar a década em um atributo separado é mais eficiente que calcular uma a uma a partir dos anos de fim e início para realização de alguns requisitos de negócios.
- **Dim_Assassino**: A tabela contém as informações relevantes referentes aos *serial killers*, o que permite analisar os perfis e cruzar características pessoais (como o gênero do criminoso) com as métricas da tabela fato. Os atributos que fazem parte da dimensão são:
 - `chave_assassino` (PK): identificador único do assassino.
 - `nome_assassino`: nome completo do criminoso disponível na página fonte.
 - `genero`: masculino ou feminino (quando disponível). Esse dado será recuperado da página individual de cada assassino.
 - `ano_de_nascimento`: ano de nascimento, que pode ser usado para calcular a idade. Esse dado será recuperado da página individual de cada assassino.
 - `pais_de_origem`: país de nascimento. Esse dado será recuperado da página individual de cada assassino.
 - `status`: situação atual do criminoso (ex: preso, morto). Esse dado será recuperado da página individual de cada assassino.

De início, foi pensada a inserção do atributo “*modus operandi*”, que forneceria informações como o tipo de arma usada ou os métodos de assassinato (ex: estrangulamento, esfaqueamento etc), contudo, após considerações e discussões entre a dupla, ficou claro que o processo de obtenção desse tipo de dado seria extremamente trabalhoso, tanto em relação à extração quanto à padronização e à transformação dos dados. Assim, ao colocar na balança as vantagens e desvantagens do atributo, foi decidido removê-lo.

- **Ponte_Localização:** A tabela ponte serve como uma intermediação entre a Dim_Localização e a Fato_Crimes, seu objetivo é permitir que um assassino esteja associado a mais de um país de atuação, de modo a manter a consistência dos dados. É uma tabela necessária para o desenvolvimento do projeto, isso porque alguns criminosos atuaram em diversos países e a tabela ponte resolve o problema do relacionamento de muitos-para-muitos do modelo. Seus atributos são parte da chave primária:
 - chave_ponte_local (PK): identifica os agrupamentos de países.
 - chave_localizacao (FK): chave estrangeira da dimensão Dim_Localização.
- **Dim_Localização:** Guarda informações relativas ao contexto geográfico da atuação dos assassinos. Essa tabela serve como um dicionário, uma referência para a tabela ponte, armazenando países e continentes para permitir análises espaciais. É composta por:
 - chave_localizacao (PK): identificador único de cada localização.
 - pais: nome do país.
 - continente: continente correspondente ao país.

1.5 Mapeamento entre atributos

Durante o processo de ETL serão realizadas as seguintes ações:

1. Remoção de caracteres especiais e *hyperlinks* de nomes e descrições;
2. Separação de valores compostos (ex: 1954-1978 para início = 1954, fim = 1978);
3. Conversão de valores em texto para numérico (como os números de vítimas);
4. Padronização de valores (ex: *status*);
5. Padronização linguística: nomes de países e territórios em inglês, tudo em letras maiúsculas.

As seguintes fontes de dados foram definidas:

1. Fonte 1 (principal): A tabela na página “Lista de *Serial Killers* por Número de Vítimas” do Wikipédia.
2. Fonte 2 (secundária): As páginas individuais da Wikipédia para cada assassino.

3. Fonte 3 (interna): Lógica de ETL (Cálculos, Regras de Negócio, Tabelas de *Lookup*).

A Tabela 1 a seguir ilustra as transformações necessárias por dimensão do DW:

Tabela Destino	Atributo Destino	Fonte de Dados	Atributo Origem	ETL
Dim_Tempo	chave tempo	Fonte 3 (Interna)	N/A	Transformação: Chave primária substituta (<i>Surrogate Key</i>).
Dim_Tempo	ano	Fonte 1 (Principal)	Coluna: "Anos em atividade"	Extração: Ler a coluna Transformação: Extrair os anos únicos (início e fim) de todos os assassinos. Carga: Criar uma linha única para cada ano.
Dim_Tempo	década	Fonte 3 (Interna)	Baseado em ano	Transformação (cálculo): SE ano >= 1990 E ano <= 1999 ENTÃO '90' (exemplo).
Dim_Localização	chave localização	Fonte 3 (Interna)	N/A	Transformação: Chave primária substituta (<i>Surrogate Key</i>).
Dim_Localização	país	Fonte 1 (Principal)	Coluna: "País"	Extração: Ler a coluna Transformação: Separar a <i>string</i> pela vírgula, tudo em letras maiúsculas. Carga: Inserir cada país único como um registro separado na tabela.
Dim_Localização	continente	Fonte 3 (Interna)	Baseado em país	Transformação: SE país = 'JAPÃO' ENTÃO 'ÁSIA' (exemplo).
Dim_Assassino	chave assassino	Fonte 3 (Interna)	N/A	Transformação: Chave primária substituta (<i>Surrogate Key</i>).
Dim_Assassino	nome assassino	Fonte 1 (Principal)	Coluna: "Nome"	Limpeza: Remover espaços extras. Cópia direta.
Dim_Assassino	gênero	Fonte 2 (Secundária)	Página individual	Extração: Leitura (<i>scraping</i>) dos pronomes Padronização: "MASCULINO" ou "FEMININO". "N/A" quando desconhecido.
Dim_Assassino	ano de nascimento	Fonte 2 (Secundária)	Página individual. <i>Infobox "Born"</i>	Extração: Ler a data de nascimento. Transformação: Extrair

				apenas o ano e converter para Inteiro.
Dim_Assassino	país de origem	Fonte 2 (Secundária)	Página individual. <i>Infobox "Born"</i>	Extração: Ler o país da <i>tag "Born"</i> no <i>Infobox</i> .
Dim_Assassino	status	Fonte 2 (Secundária)	Página individual. <i>Infobox</i>	Extração: <i>Tag "Died"</i> ou <i>"Criminal Penalty"</i> Transformação: Se há a <i>tag died</i> então status é "MORTO", caso contrário a <i>tag "Criminal Penalty"</i> é checada, caso tenha a palavra <i>"Life"</i> está preso, caso não tenha, a <i>tag "Date apprehended"</i> é checada e somada aos anos de sentença para saber se está preso ou solto.
Ponte_Localização	chave ponte local	Fonte 3 (Interna)	N/A	Transformação: Chave substituta para o grupo de localizações. Para cada combinação única de países (ex: o grupo "COLÔMBIA, PERU, EQUADOR"), é gerada uma chave (ex: 1001).
Ponte_Localização	chave localização	Fonte 1 (Principal) + Fonte 3 (Interna)	Coluna: "País" + Dim_Localização	Extração: Ler "COLÔMBIA, PERU, EQUADOR". Transformação: Separar em ["COLÔMBIA", "PERU", "EQUADOR"]. <i>Lookup</i> : Buscar a chave localização de cada um na Dim_Localização (ex: 5, 12, 13). Carga: Inserir 3 linhas na Ponte_Localização: (1001, 5), (1001, 12), (1001, 13).
Fato_Crimes	chave ano início	Fonte 1 (Principal) + Fonte 3 (Interna)	Coluna: "Anos em atividade" + Dim_Tempo	Extração: Ler "1992 a 1999", extrair o ano de início (1992). <i>Lookup</i> : Buscar na Dim_Tempo onde ano = 1992 e obter a chave tempo.

Fato_Crimes	chave ano final	Fonte 1 (Principal) + Fonte 3 (Interna)	Coluna: "Anos em atividade" + Dim_Tempo	Extração: Ler "1992 a 1999", extrair o ano de fim (1999). <i>Lookup:</i> Buscar na Dim_Tempo onde ano = 1999 e obter a chave tempo.
Fato_Crimes	chave ponte local	Fonte 3 (Interna)	Ponte_Localização	<i>Lookup:</i> É a chave do grupo gerada durante o processo da tabela ponte.
Fato_Crimes	chave assassino	Fonte 1 (Principal) + Fonte 3 (Interna)	Coluna: "Nome" + Dim_Assassino	<i>Lookup:</i> Buscar na Dim_Assassino onde nome_assassino = "LUIS GARAVITO" e obter a chave assassino.
Fato_Crimes	vítimas possíveis	Fonte 1 (Principal)	Coluna: "Vítimas possíveis"	Limpeza: Remover caracteres não numéricos. Transformação: Converter para Inteiro. Tratamento: Se nulo ou vazio, definir como 0.
Fato_Crimes	vítimas confirmadas	Fonte 1 (Principal)	Coluna: "Vítimas provadas"	Limpeza: Remover caracteres não numéricos. Transformação: Converter para Inteiro. Tratamento: Se nulo ou vazio, definir como 0.
Fato_Crimes	quantidade de países	Fonte 3 (Interna)	Ponte_Localização	Transformação (Agregação): Durante a carga da Fato, após o chave_ponte_local (ex: 1001) ser definido, executar uma consulta de agregação COUNT, contar quantas vezes chave_ponte_local aparece em Ponte_Localização. Carga: Salvar o resultado (ex: 3) nesta coluna.
Fato_Crimes	anos em atividade	Fonte 1 (Principal)	Coluna: "Anos em atividade"	Transformação (Cálculo): [Ano Final] - [Ano Inicial]

Fato_Crimes	idade de início	Fonte 1 (Principal) + Fonte 2 (Secundária)	"Anos em atividade" + "Nascimento"	Integração: Obter Ano_Inicio (da Fonte 1) e Ano_Nascimento (da Fonte 2) Transformação (Cálculo): [Ano_Inicio] - [Ano_Nascimento]
-------------	-----------------	--	------------------------------------	---

Tabela 1 - Relação dimensão-ação

2. IMPLEMENTAÇÃO

Esta seção traz as etapas de implementação do DW no ambiente *Databricks*, incluindo tanto o mapeamento do modelo lógico para físico quanto a execução do processo de ETL e construção do fluxograma de processamento de dados.

2.1 Projeto físico

O projeto físico corresponde à implementação do modelo lógico do *Data Warehouse* dentro do *Databricks*. O modelo multidimensional foi mapeado em tabelas de modo a permitir o armazenamento dos dados no ambiente *Spark*.

As tabelas dimensão e a fato foram criadas com base nos atributos definidos na modelagem conceitual, respeitando as chaves primárias e estrangeiras estabelecidas anteriormente.

Cada tabela recebe um identificador *surrogate key* gerado automaticamente, garantindo, assim, a integridade e consistência durante as etapas de carga. Também foi adotada a estrutura de camadas (bronze, prata e ouro) para organizar os níveis de tratamento dos dados:

- Camada Bronze: traz os dados brutos diretamente da página da Wikipédia, sem o tratamento.
- Camada Prata: é onde os dados passam pela limpeza, padronização e integração entre as fontes. Aplicam-se as regras de ETL definidas na seção anterior para devolver dados prontos para a próxima camada.
- Camada Ouro: aqui os dados estão consolidados e prontos para as consultas no formato do modelo estrela.

A estrutura em camadas proporciona diversas vantagens, como a questão da rastreabilidade dos dados e manutenção do *pipeline*.

2.2 ETL

O processo de ETL foi implementado no *Databricks* usando a biblioteca *PySpark* e seguindo as definições da Seção 1. Abaixo uma breve descrição de cada uma das fases:

1. Extração: os dados foram retirados diretamente da página “*List of Serial Killers by Number of Victims*” da Wikipédia, utilizando, majoritariamente, a API pública. Para alguns outros dados, como os encontrados nas páginas pessoais de cada assassino, foi usada a técnica de *scraping*.
2. Transformação: aqui, foram aplicadas as operações de limpeza e padronização, incluindo a remoção dos *hyperlinks* e caracteres especiais, separação dos anos em “início” e “fim”, conversão de texto em valor numérico, padronização de nomes (países, *status*, gênero etc) e criação das colunas derivadas presentes no nosso modelo multidimensional - como `anos_em_atividade` e `década`. Todas essas transformações ocorrem, inicialmente, na camada Prata, de modo a garantir que apenas dados consistentes sejam carregados para o DW.
3. Carga: depois das transformações necessárias, os dados já limpos e tratados são carregados nas tabelas (dimensões e fato) da camada Ouro.

2.2.1 Fluxograma

Aqui ilustra-se o caminho dos dados, partindo da extração até o carregamento no DW. Cada etapa é associada a um nível de “pureza” dos dados, seguindo o esquema de camadas Bronze-Prata-Ouro.

De modo geral, o fluxo descreve:

1. Coleta (Bronze): dados extraídos via API e *scraping* são armazenados em formato bruto.
2. Tratamento (Prata): padronização, limpeza, correção de valores, cálculos.
3. Integração (Ouro): dados consistentes e estruturados em formato de esquema estrela, já prontos para aplicar consultas.

As Figuras 2 e 3 abaixo ilustram o caminho dos dados entre as camadas Bronze, Prata e Ouro. A Figura 2 é um fluxograma gerado via Lucidchart, já a Figura

3 é o *pipeline* do projeto gerado no próprio Databricks a partir dos códigos presentes neste *notebook*.




Figura 2 - Fluxograma do ETL




Figura 3 - Pipeline do projeto

2.2.2 Desenvolvimento da extração de dados

O desenvolvimento foi feito em Python no Databricks, todo o código usado foi reunido no *notebook* *NTBD_FF_Grupo3_amanda_daniel.ipynb*.

As informações coletadas foram armazenadas na camada Bronze em formato de *DataFrame*, por conseguinte, as etapas de limpeza e transformação foram implementadas, seguindo a lógica de construção de um *pipeline* de dados visto em sala de aula. Cada uma das tabelas foi gerada em sequência: primeiro as dimensões e depois a fato, usando *lookups* para garantir a integridade referencial.

Finalmente, os dados tratados foram salvos em tabelas Delta dentro do *catalog* do *Databricks*, compondo a camada Ouro e servindo como base para as consultas e *views*.

2.3 Consultas

De modo a validar o modelo e responder aos requisitos propostos ao início do projeto, foram executadas as consultas sobre a camada Ouro. A seguir, estão descritas as consultas desenvolvidas e uma breve explicação sobre cada uma. Os

resultados completos de cada uma delas estão presentes no *notebook* de nome *NTBD_FF_Grupo3_amanda_daniel.ipynb*.

2.3.1 Qual a soma total de vítimas (confirmadas e possíveis) dos assassinos que atuaram em mais de um país?

SQL:

```
SELECT
    SUM(vitimas_provasdas) AS total_confirmadas,
    SUM(vitimas_possiveis) AS total_possiveis,
    SUM(vitimas_provasdas + vitimas_possiveis) AS
total_geral
FROM fato_crimes
WHERE qtd_paises_atuacao > 1;
```

Esta consulta agrega o número de vítimas para os assassinos cuja quantidade de países de atuação é superior a 1. A análise pode ser relevante em um contexto de comparação entre a letalidade de assassinos que atuam internacionalmente e assassinos que atuam apenas em um país.

2.3.2 Qual a idade média de início dos assassinatos por gênero?

SQL:

```
SELECT
    d.genero,
    ROUND(AVG(f.idade_inicio), 1) as media_idade_inicio,
    COUNT(f.id_assassino) as qtd_amostra
FROM workspace.public.fato_crimes f
JOIN workspace.public.dim_assassino d ON f.id_assassino =
d.id_assassino
WHERE f.idade_inicio > 0
    AND d.genero != 'UNKNOWN'
GROUP BY d.genero
ORDER BY media_idade_inicio ASC
```

Usando a dimensão de assassino e a tabela fato, a consulta permite calcular a idade média de início dos crimes separados por gênero.

2.3.3 A duração média dos anos em atividade dos *Serial Killers* diminuiu após o teste de DNA começar a ser usado em investigações criminais?

SQL:

```
SELECT
    CASE
        WHEN id_tempo_final < 1986 THEN '1. Pré-DNA
(Antes de 1986)'
        ELSE '2. Pós-DNA (1986 em diante)'
    END AS era_investigacao,
    ROUND(AVG(anos_em_atividade), 1) as
media_anos_atividade,
    COUNT(id_assassino) as qtd_amostra
FROM workspace.public.fato_crimes
WHERE id_tempo_final > 0
    AND id_tempo_inicio > 0
    AND anos_em_atividade >= 0
    -- AQUI ESTÁ O FILTRO: Excluimos quem viveu na
transição
    -- Ou terminou antes de 86 (Pré Puro) OU começou depois
de 86 (Pós Puro)
    AND (id_tempo_final < 1986 OR id_tempo_inicio >= 1986)
GROUP BY 1
ORDER BY 1 ASC
```

De modo a avaliar se o tempo de atividade diminuiu após a popularização do DNA forense, a consulta agrupa a média de anos em atividade antes e depois desse marco temporal.

2.3.4 Comparando assassinos da "América do Sul" vs. "América do Norte", qual deles tem o maior número de *serial killers* com status "PRESO" para aqueles que iniciaram atividade nos anos "1990"?

SQL:

```
SELECT
    l.continente,
    COUNT(DISTINCT a.id_assassino) AS
total_assassinos_presos
FROM fato_crimes f
JOIN dim_assassino a ON f.id_assassino = a.id_assassino
JOIN ponte_localizacao p ON a.id_assassino =
p.id_assassino
JOIN dim_localizacao l ON p.id_localizacao =
l.id_localizacao
WHERE
    l.continente IN ('NORTH AMERICA', 'SOUTH AMERICA')
    AND f.id_tempo_inicio BETWEEN 1990 AND 1999
    AND a.status = 'PRESO'
GROUP BY l.continente;
```

Essa consulta realiza uma junção entre as dimensões de assassino, localização, tabela ponte e a tabela fato, filtrando aqueles assassinos que iniciaram a atividade na década de 1990. Dessa forma, é possível comparar o número de assassinos presos na América do Sul *versus* América do Norte.

3. CONSIDERAÇÕES FINAIS

O desenvolvimento deste projeto permitiu, de maneira prática, consolidar os conceitos trabalhados ao longo da disciplina. A construção do *pipeline* em camadas (arquitetura bronze-prata-ouro) reforçou as noções fundamentais de ETL, tratamento de dados, padronização e modelagem dimensional. Ao longo do trabalho, foi necessário lidar com desafios como a inconsistência dos dados: informações ausentes ou incorretas, fontes diferentes de dados e relações multivaloradas (número de países).

O modelo obtido foi um esquema estrela e se demonstrou adequado para aquilo que definimos como requisitos de negócio. A criação das tabelas (tanto fato quanto dimensões e ponte) tornou possível a execução das consultas e análise consistente das informações. As visualizações também foram essenciais para identificar padrões e facilitar nosso entendimento quanto aos requisitos.

Além dos aspectos técnicos citados, o projeto também forneceu uma experiência valiosa no uso de ferramentas de engenharia de dados, como o Databricks e PySpark. O uso constante dessas tecnologias nas aulas, além de ajudar imensamente no desenvolvimento do trabalho, também nos possibilitou compreender melhor sua aplicabilidade em cenários reais.

De forma geral, o projeto permitiu a integração entre teoria e prática, reforçando os conceitos estudados ao longo da disciplina, como a criação de chaves, modelagem, análise exploratória e ingestão de dados. A experiência evidenciou a importância dessas técnicas na construção de soluções analíticas.

4. BIBLIOGRAFIA

KIMBALL, Ralph; ROSS, Margy. ***The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling***. 3rd ed. Hoboken: John Wiley & Sons, 2013.

WIKIPÉDIA. ***List of serial killers by number of victims***. Disponível em: https://en.wikipedia.org/wiki/List_of_serial_killers_by_number_of_victims. Acesso em: 2025.

FOGONWATER. ***Countries and continents***. Gist, 23 jan. 2025. Disponível em: <https://gist.github.com/fogonwater/bc2b98baeb2aa16b5e6fbc1cf3d7d545>. Acesso em: dez. 2025.